

中小微企业的信贷决策研究

基于监督违约概率、单调流失率与混合整数规划

冯浩然

摘要: 针对仅有企业基础信息和进销项发票、且有标签样本仅 123 家的中小微企业信贷决策问题, 本文建立“监督违约概率、经营质量辅助解释、利率与额度联合优化、突发冲击重优化”的闭环模型。首先保留有效发票金额的正负符号, 按连续自然月补零, 构造规模、盈利、稳定性、活跃度、趋势、作废及红冲等 16 个特征。随后采用带 L_2 正则和类别平衡权重的逻辑回归估计违约概率, 通过 5 次重复的 5 折嵌套分层交叉验证获得严格样本外预测, 并用固定 PD 阈值划分 A 至 D 四档。模型样本外 ROC-AUC 为 0.856, PR-AUC 为 0.734, Brier 分数为 0.107。TOPSIS 不再承担违约预测, 而是在附件 1 确定缩放边界和理想点后迁移至附件 2, 用于解释经营质量。对附件 3 采用保序回归得到随利率非降的客户流失率曲线, 并以留存后利息、违约损失和资金成本构造单位额度期望收益。在原始 D 级和预测 D 级禁贷、单户额度为 0 或 10 至 100 万元、总预算精确满足的条件下, 用混合整数线性规划配置贷款。疫情冲击通过赔率乘数作用于 PD 后重新评级、定价和分配。最终问题 1、2、3 分别向 80、100、100 家企业授信, 期望净收益分别为 70.54、133.56、132.19 万元。100 次真实权重扰动的 Spearman 相关系数均值为 0.9983。模型把预测、定价、分配和压力测试放入同一可复算流程, 并明确区分数据事实、模型结果和业务假设。

关键词: 中小微企业; 违约概率; 逻辑回归; 保序回归; 混合整数规划; 信贷定价

目录

1 问题重述与任务拆解	4
2 问题分析与总体建模路线	4
2.1 为什么不能直接使用银行原评级	4
2.2 为什么 TOPSIS 不是风险主模型	4
2.3 完整流程	5
3 数据理解、基本假设与符号	5
3.1 数据规模	5
3.2 基本假设	6
3.3 主要符号	6
4 从发票到企业特征	7
4.1 票据口径与有符号净额	7
4.2 连续月历与经营断档	7
4.3 16 项 PD 特征	8
5 监督违约概率模型	8
5.1 为什么选择正则逻辑回归	8
5.2 类别平衡与 L2 正则	9
5.3 为什么还需要先验校正	9
5.4 嵌套重复样本外验证	9
6 PD 等级与模型验证	10
6.1 固定风险档位	10
6.2 四个验证指标怎样理解	10
7 固定尺度 TOPSIS 辅助解释	12
7.1 经营质量分数的作用	12
8 利率、客户流失与期望收益	13
8.1 为什么利率不能只取最高值	13
8.2 保序流失率模型	13

8.3 单位额度期望收益	14
9 混合整数额度优化	15
9.1 从单户收益到银行组合	15
9.2 三问策略结果	15
10 疫情冲击下的重新决策	16
10.1 行业分类和冲击系数	16
10.2 为什么冲击作用于赔率	16
11 灵敏度与稳健性分析	17
11.1 真实权重扰动	17
12 模型评价、局限与扩展	18
12.1 模型优点	18
12.2 主要局限	18
12.3 扩展方向	19
13 结论	19

1 问题重述与任务拆解

某银行拟向中小微企业发放一年期贷款，单户额度为 10 至 100 万元，年利率范围为 4% 至 15%。附件 1 给出 123 家有信贷记录企业的信誉评级、是否违约标签以及进销项发票；附件 2 给出 302 家无信贷记录企业的基础信息和发票；附件 3 给出不同信誉等级下贷款利率与客户流失率的统计关系。

题目表面上要求给出额度和利率，实际包含四个连续问题：

1. 如何把几十万张发票压缩为能够反映经营状况的企业特征；
2. 如何用有标签企业学习“未来发生违约的可能性”；
3. 如何在利率收入、客户流失、违约损失和资金成本之间取舍；
4. 如何在预算、禁贷和单户上下限约束下形成可执行的组合方案。

如果只给企业排一个综合名次，就无法回答“违约概率是多少”；如果只预测违约概率，又无法回答“利率和额度是多少”。因此本文把问题拆成风险预测、经营解释、定价和组合优化四层，每层只承担一个明确任务。

直觉理解：把整道题看成银行的一条决策流水线

发票数据回答企业过去经营得怎么样；监督模型回答企业未来违约的可能性；流失率模型回答客户是否愿意接受某个利率；优化模型回答有限资金应当投给谁。前一层的输出是后一层的输入，而不是四个互不相关的方法。

2 问题分析与总体建模路线

2.1 为什么不能直接使用银行原评级

附件 2 没有银行信誉评级，原评级无法直接迁移；同时，附件 1 的评级是人工综合判断，不等同于真实违约标签。本文保留原评级用于准入约束和对照分析，但用“是否违约”训练概率模型。这样既尊重银行已有规则，也使附件 2 获得统一的风险尺度。

2.2 为什么 TOPSIS 不是风险主模型

TOPSIS 适合回答“哪个企业更接近理想经营状态”，但它没有直接利用违约标签。若把 TOPSIS 分数直接当作 PD，会把经营质量排序和违约概率混为一谈。因此本文用逻辑回归估计 PD，用 TOPSIS 解释企业经营质量，二者职责分开。

2.3 完整流程




图 1 从原始发票到信贷策略的完整流程

PD 是风险主线，TOPSIS 是解释支线。流失率把利率和客户接受行为连接起来，MILP 把单户最优收益转化为全行预算下的组合方案。疫情发生后不是简单缩减原额度，而是重新运行 PD 调整、评级、定价和额度优化。

3 数据理解、基本假设与符号

3.1 数据规模

附件 1 共有 373431 条进销项发票，附件 2 共有 726010 条。附件 1 中已知违约企业为 27 家，样本违约率为 22.0%。附件 3 包含 29 个利率与流失率观测点。数据量最大的部分是票据明细，而真正用于监督学习的企业样本只有 123 家，因此模型应优先稳定和可解释，不宜盲目使用复杂黑箱。




图 2 附件 1 与附件 2 的数据规模

3.2 基本假设

表 1 主要假设及其作用

假设	取值	说明
贷款期限	1 年	与题目一致，利率和损失均按一年期计算
问题 1 预算	8000 万元	题目未明确给出，作为可配置情景，不把它视为数据事实
问题 2 与 3 预算	10000 万元	按题目给出的 1 亿元年度额度
违约损失率 LGD	60%	违约后本金的期望损失比例，可由银行回收数据替换
资金成本率	2.5%	银行投放资金的机会成本，可按真实资金价格更新
客户流失	不接受贷款	流失客户不产生放款、利息、损失和资金成本
行业冲击	作用于赔率	用于情景压力测试，不视为疫情的精确因果估计

3.3 主要符号

表 2 主要符号说明

符号	名称	含义
i	企业索引	附件中的某一家企业
y_i	违约标签	违约取 1，不违约取 0
$\mathbf{x}_i$	特征向量	企业的规模、盈利、稳定性、活跃度和票据行为
p_i	违约概率 PD	模型预测企业一年内违约的概率
r_i	贷款年利率	在附件 3 的观测利率网格上选择
$c_i(r)$	客户流失率	企业面对利率 r 时拒绝贷款的概率
$q_i(r)$	客户留存率	$q_i(r) = 1 - c_i(r)$
L	LGD	违约时的损失比例，本文取 60%
c_f	资金成本率	本文取 2.5%
$u_i(r)$	单位额度期望收益	每投放 1 万元给企业 i 的期望净收益
x_i	授信额度	企业 i 获得的名义贷款额度，单位为万元
z_i	选择变量	获贷为 1，不获贷为 0
B	总预算	问题 1 为 8000 万元，问题 2 和 3 为 10000 万元
k_i	疫情冲击系数	乘到企业的违约赔率上

4 从发票到企业特征

4.1 票据口径与有符号净额

对状态为“有效发票”的记录使用不含税金额列，并保留正负符号。正数票据表示正常交易，负数票据通常对应红冲或退货，应冲减而不是取绝对值。企业 i 的销项净额定义为

$$R_i = \sum_{j \in \mathcal{V}_i^{out}} a_{ij}, \quad (1)$$

其中 $\mathcal{V}_i^{out}$ 为有效销项票据集合， a_{ij} 为有符号金额。进项净额 C_i 同理。税额不与金额重复相加；作废票据不进入净额，但其数量进入作废率特征。

直觉理解：为什么负数发票不能取绝对值

假设企业先开出 100 万元销项发票，随后发生 20 万元退货并开具 -20 万元红冲票。真实销售净额是 $100 - 20 = 80$ 万元。如果对负数取绝对值，就会得到 $100 + 20 = 120$ 万元，收入被高估 50%。若 20 万元票据是作废票，则它完全不进入净额，但会提高作废率。

4.2 连续月历与经营断档

对每家企业，从第一张到最后一张有效票据构造连续自然月序列，无交易月份补 0。设观察月数为 M_i ，有交易的月份为 A_i ，则

$$\text{ActiveRatio}_i = \frac{A_i}{M_i}, \quad \text{AnnualRevenue}_i = \frac{12R_i}{M_i}. \quad (2)$$

直觉理解：补 0 和删除月份有什么区别

一家企业 6 个月内只有 1 月和 6 月有收入。如果只保留有收入的两个月，它看起来“每个月都在经营”；补齐 2 月至 5 月的 0 之后，活跃月份比例只有 $2/6$ ，中间断档被保留下来。风险模型由此能够区分持续经营与偶发大额交易。

最近断档月数记录最后一个有交易月份至观察期末的间隔；收入和成本波动率使用连续月序列标准差除以平均绝对规模；趋势率由月份序号对月净额的线性斜率再除以平均绝对规模得到。所有分母为 0 的比率按 0 处理，最终数值列检查并消除缺失值和无穷值。

4.3 16 项 PD 特征

表 3 监督 PD 模型的特征分组

维度	特征	风险含义
规模与盈利	年化销项净额、年化利润、利润率、年化客户数、年化供应商数	衡量经营规模、盈利空间和交易网络
稳定与趋势	收入波动率、成本波动率、收入趋势率	识别经营剧烈波动或持续收缩
经营连续性	活跃月份比例、最近断档月数	识别长期停顿和低频经营
票据行为	进销项作废率、负数发票率、负数金额率	反映作废、红冲、退货等异常或经营特征

年化销项净额、年化利润、客户数和供应商数呈明显长尾，先做有符号对数变换

$$T(x) = \text{sign}(x) \log(1 + |x|), \quad (3)$$

再用训练折的 1% 和 99% 分位点截尾，并按训练折均值、标准差进行标准化。验证折和附件 2 只应用训练阶段得到的参数，避免把未来或待预测数据的信息泄漏进模型。

5 监督违约概率模型

5.1 为什么选择正则逻辑回归

附件 1 只有 123 家企业和 27 个违约样本。复杂模型虽然能提高训练集拟合度，却可能只记住少数企业。逻辑回归直接输出 0 至 1 之间的概率，系数方向可解释，配合 L_2 正则能抑制小样本下的系数剧烈波动，因此适合作为主模型 [1, 2]。

令 $y_i = 1$ 表示违约，标准化特征向量为 $\mathbf{x}_i$ ，线性风险得分为

$$z_i = \beta_0 + \mathbf{x}_i^T \boldsymbol{\beta}, \quad (4)$$

再通过 Sigmoid 函数转为 PD:

$$\hat{p}_i = \sigma(z_i) = \frac{1}{1 + e^{-z_i}}. \quad (5)$$

直觉理解：线性得分如何变成概率

如果某企业的标准化特征经过系数加权后得到 $z = 0$ ，则 $\sigma(0) = 0.5$ ；若 $z = -2$ ，PD 约为 11.9%；若 $z = 2$ ，PD 约为 88.1%。Sigmoid 函数把任意实数压缩到 0 和 1 之间，同时保留风险高低顺序。

5.2 类别平衡与 L2 正则

非违约企业明显多于违约企业。如果所有企业权重相同，模型可能偏向多数类。本文让两类样本的总训练权重各占一半：

$$w_i = \begin{cases} \frac{n}{2n_1}, & y_i = 1, \\ \frac{n}{2n_0}, & y_i = 0, \end{cases} \quad (6)$$

其中 n_1, n_0 分别为违约和非违约数量。优化目标为

$$\min_{\beta_0, \beta} \frac{1}{\sum_i w_i} \sum_i w_i [\log(1 + e^{z_i}) - y_i z_i] + \frac{\lambda}{2} \|\beta\|_2^2. \quad (7)$$

后一项是 L_2 惩罚。 λ 越大，系数越接近 0，模型更平滑但可能欠拟合； λ 越小，模型更贴合训练数据但可能过拟合。最终全样本模型选择 $\lambda = 0.10$ 。

5.3 为什么还需要先验校正

类别平衡让训练过程暂时把两类看得同样重要，但真实样本违约率只有 22.0%。若直接输出平衡训练概率，会系统性高估 PD。因此在预测时把训练折真实违约率 π 的对数赔率加回：

$$\hat{p}_i = \sigma \left(\hat{z}_i + \log \frac{\pi}{1 - \pi} \right). \quad (8)$$

这一步不改变企业大致风险顺序，但把概率水平拉回真实样本基准。它回答的是“在真实违约率背景下，这家企业大约有多大风险”，而不是“在两类被人为平衡后，模型有多确信”。

5.4 嵌套重复样本外验证

若在训练模型的同一批企业上评价，模型可能因为记住样本而显得过于优秀。本文采用外层 5 次重复、每次 5 折的分层交叉验证；每个外层训练集内部再用 4 折交叉验证，从 $\{0.01, 0.1, 1, 10\}$ 中选择 λ 。

一次外层循环的步骤是：

1. 把约 80% 企业作为外层训练集，约 20% 作为外层测试集，并保持违约比例接近；
2. 只在外层训练集内部选择 λ ；
3. 只用外层训练集计算截尾点、均值和标准差；
4. 训练模型并预测从未参与训练的外层测试企业；
5. 重复直到每家企业都获得一次样本外预测；更换随机划分后再重复 5 次，最后取均值。

直觉理解：内层和外层分别做什么

内层负责“选模型”，例如决定正则强度；外层负责“考模型”，只评价已经选好的完整流程。如果用同一折既选参数又报成绩，测试集就间接参与了模型选择，结果仍会偏乐观。

6 PD 等级与模型验证

6.1 固定风险档位

为使不同附件和未来批次具有相同含义，PD 档位采用固定阈值，而不是每批企业按人数分位数强行分组：

$$g(p) = \begin{cases} A, & 0 \leq p < 0.10, \\ B, & 0.10 \leq p < 0.20, \\ C, & 0.20 \leq p < 0.40, \\ D, & p \geq 0.40. \end{cases} \quad (9)$$

6.2 四个验证指标怎样理解

- **ROC-AUC**：随机抽取一个违约企业和一个非违约企业，模型把违约企业排在更高风险位置的概率。0.5 近似随机，越接近 1 越好。
- **PR-AUC**：关注高风险名单中违约企业能否被找出，特别适合违约样本较少的情况。
- **Brier 分数**：预测概率与 0/1 真实结果的平均平方差，越小越好。它同时惩罚过高和过低的概率。
- **Log Loss**：对“非常自信但判断错误”的预测处罚更重，越小越好。

表 4 重复嵌套样本外预测性能

指标	ROC-AUC	PR-AUC	Brier	Log Loss
数值	0.856	0.734	0.107	0.357

表 5 固定 PD 档位的样本外违约表现

等级	企业数	违约数	实际违约率	平均预测 PD
A	56	3	5.4%	5.6%
B	32	4	12.5%	13.6%
C	15	4	26.7%	28.8%
D	20	16	80.0%	61.1%




图 3 PD 模型的分档验证与迁移结果

ROC-AUC 为 0.856，说明模型能较好地地区分风险顺序；D 档 20 家企业中有 16 家实际违约，实际违约率 80.0%，高风险得到集中识别。A、B、C、D 档的实际违约率依次上升，固定阈值具有业务解释力。但附件 1 只有 123 家企业，单个档位样本仍少，因此这些概率适合用于组合决策，不应被理解为永不变化的精确真值。




图 4 风险模型解释与原评级对照

系数为正表示该特征增加时模型 PD 倾向上升，系数为负表示 PD 倾向下降。由于特征之间可能相关，单个系数反映“其他特征不变时”的方向，不代表直接因果关系。模型等级与银行原评级不完全相同是正常现象：银行评级包含人工经验，模型等级则只依据发票和历史标签。

7 固定尺度 TOPSIS 辅助解释

7.1 经营质量分数的作用

逻辑回归回答“企业会不会违约”，TOPSIS 回答“企业在经营规模、盈利、稳定和票据行为上离理想状态有多近”。本文使用 14 项经营质量指标，其中规模、盈利、活跃度和趋势为效益型，波动、断档、作废和负数金额率为成本型 [3]。

对附件 1 第 j 项指标确定 1% 和 99% 截尾点并作 0 至 1 归一化；附件 2 沿用附件 1 的同一边界，超出范围时截到 $[0, 1]$ 。正负理想点和权重也只在附件 1 确定，避免待评价企业改变评分尺子。

设归一化加权向量为 $\mathbf{v}_i$ ，正、负理想点为 $\mathbf{v}^+$ 和 $\mathbf{v}^-$ ，则

$$D_i^+ = \|\mathbf{v}_i - \mathbf{v}^+\|_2, \quad D_i^- = \|\mathbf{v}_i - \mathbf{v}^-\|_2, \quad S_i = \frac{D_i^-}{D_i^+ + D_i^-}. \quad (10)$$

直觉理解：为什么附件 2 不能重新归一化

假设附件 1 中最高年收入是 1000 万元，某企业收入 500 万元，对应相对水平约 0.5。如果附件 2 最高收入只有 600 万元，并在附件 2 内重新缩放，同样 500 万元会变成接近 0.83。评分变化来自参照群体而不是企业本身。固定附件 1 尺度后，同样经营状态得到相同解释。




图 5 PD 风险与 TOPSIS 经营质量的互补解释

TOPSIS 得分用于报告排序、个案分析和灵敏度检验，不参与 PD 档位定义，也不直接决定贷款利率。这样可以避免把主观权重伪装成违约概率，同时保留多指标评价的解释优势。

8 利率、客户流失与期望收益

8.1 为什么利率不能只取最高值

提高利率会增加每一笔成功贷款的利息，但也可能让客户转向其他银行。特别是低风险企业通常有更多融资渠道，对高利率更敏感。因此利率决策必须同时考虑“每笔赚多少”和“客户是否接受”。

8.2 保序流失率模型

附件 3 的流失率存在少量局部下降点，这可能来自抽样波动。为满足“利率上升时流失率不下降”的经济约束，对 A、B、C 级分别用 PAVA 保序回归求解 [4]：

$$\min_{\tilde{c}_1, \dots, \tilde{c}_m} \sum_{k=1}^m (c_k - \tilde{c}_k)^2, \quad \tilde{c}_1 \leq \dots \leq \tilde{c}_m. \quad (11)$$

PAVA 会把违反顺序的相邻点合并为加权平均，直到整条曲线非降。任意候选利率的流失率通过分段线性插值得到；D 级不进入定价，因为其被禁贷。




图 6 单调约束下的利率与客户流失率曲线

8.3 单位额度期望收益

设企业 i 的 PD 为 p_i ，利率为 r ，客户留存率为 $q_i(r) = 1 - c_i(r)$ ，违约损失率为 L ，资金成本率为 c_f 。每 1 万元名义授信的期望净收益为

$$u_i(r) = q_i(r) [(1 - p_i)r - p_iL - c_f]. \quad (12)$$

括号内三项分别是未违约利息、违约损失和资金成本；最外层 $q_i(r)$ 表示只有客户留存时才会实际发生放款。对附件 3 出现过的利率逐点计算 $u_i(r)$ ，选择最大值对应的利率，避免对观测区间之外进行不可靠外推。

直觉理解：100 万元贷款的收益怎么算

假设某企业 PD 为 8%，利率 10%，流失率 20%，则留存率为 80%。取 LGD 为 60%、资金成本为 2.5%，每 1 万元的期望净收益为

$$0.8 \times [(1 - 0.08) \times 0.10 - 0.08 \times 0.60 - 0.025] = 0.0152 \text{ 万元}.$$

如果名义授信 100 万元，期望净收益约 1.52 万元。把利率提高后，括号中的利息会增加，但留存率可能下降，净收益不一定提高。

9 混合整数额度优化

9.1 从单户收益到银行组合

即使知道每家企业的最佳利率和单位收益，也不能逐家独立决定额度，因为所有企业共同占用有限预算。令 x_i 为授信额度， $z_i \in \{0, 1\}$ 表示是否授信，优化模型为

$$\max_{x, z} \quad \sum_i u_i^* x_i, \quad (13)$$

$$\text{s.t.} \quad \sum_i x_i = B, \quad (14)$$

$$10z_i \leq x_i \leq 100z_i, \quad (15)$$

$$x_i = 0, \quad i \in \{\text{原始 D 级或预测 D 级}\}. \quad (16)$$

第一条约束要求预算精确使用；第二条把“0 或 10 至 100 万元”转成线性约束；第三条执行 D 级禁贷。这是一个混合整数线性规划，连续变量 x_i 决定额度，二元变量 z_i 决定是否入选，由 SciPy 的 MILP 求解器求全局最优可行解。

直觉理解：用 4 家企业理解额度分配

假设 4 家企业的单位收益依次为 2.0%、1.5%、0.8%、-0.2%，预算 150 万元，单户上限 100 万元。若没有其他约束，模型会先给第一家 100 万元，再给第二家 50 万元，而不会为了“平均”把 37.5 万元分给每家。真实模型同理：额度首先流向单位收益更高的合格企业。

当前目标函数对 x_i 是线性的，且题目只给出统一单户上限，因此最优解通常把入选企业推到 100 万元上限。若银行希望更加分散，应增加企业申请额度、行业集中度或边际收益递减约束，而不应在求解后随意手工均摊。

9.2 三问策略结果

表 6 三问信贷策略摘要

方案	放贷企业数	额度合计/万元	平均利率	期望净收益/万元
问题 1	80	8000	12.31%	70.54
问题 2	100	10000	10.28%	133.56
问题 3	100	10000	10.35%	132.19




图 7 三问留存后利息、违约损失、资金成本和净收益

问题 1 在 8000 万元假设预算下向 80 家企业放贷，问题 2 在 1 亿元预算下向 100 家企业放贷。原始 D 级获贷企业数为 0，说明准入规则得到严格执行。净收益是模型期望值而不是保证利润，其意义是用于比较策略和资源配置，不是承诺银行一定获得相同金额。

10 疫情冲击下的重新决策

10.1 行业分类和冲击系数

根据企业名称中的行业关键词，把企业划分为严重负面、中度负面、正面或轻影响、其他和未知五类。对于仅有“个体经营 E 编号”而没有行业语义的企业，标记为未知，不强行猜测行业。严重负面、中度负面和正面或轻影响的赔率系数分别为 1.30、1.15 和 0.90，其他与未知取 1.00。

这些系数是可配置压力情景，不是由当前附件估计出的疫情因果效应。若银行获得正式行业代码和疫情期间违约数据，应重新估计行业冲击。

10.2 为什么冲击作用于赔率

概率不能无限放大，直接计算 $k_i p_i$ 在高 PD 时可能超过 1。赔率定义为 $p/(1-p)$ ，取正值且没有 1 的上界，因此令

$$\text{odds}(p'_i) = k_i \text{odds}(p_i), \quad p'_i = \frac{k_i p_i}{1 - p_i + k_i p_i}. \quad (17)$$

直觉理解：赔率调整示例

若企业原 PD 为 20%，原赔率为 $0.20/0.80 = 0.25$ 。严重负面冲击系数 1.30 使赔率变为 0.325，对应新 PD 为 $0.325/(1 + 0.325) \approx 24.5\%$ 。新概率始终位于 0 和 1 之间，而且对原本高风险企业不会产生越界值。

调整 PD 后重新划分等级，再重新选择利率并运行 MILP。这样受冲击企业不仅额度可能下降，利率、准入状态和组合中的相对位置也会同步变化。最终共有 8 家企业跨越风险等级阈值。




图 8 疫情赔率冲击前后各行业类别的平均授信额度

行业关键词来自脱敏名称，部分企业无法可靠识别。问题 3 的价值是展示“冲击发生后如何重新决策”的机制，而不是宣称已经准确预测疫情影响。正式应用中应把关键词分类替换为标准行业代码，并用多个冲击系数形成轻度、中度和重度情景。

11 灵敏度与稳健性分析

11.1 真实权重扰动

对 TOPSIS 基准权重进行 100 次独立扰动，每个权重乘以 $U(0.8, 1.2)$ 后重新归一化。每次都从原始特征重新计算 TOPSIS 得分和完整排名，再与基准排名计算 Spearman 和 Kendall 相关系数，而不是围绕某个预设均值随机生成相关系数。

Spearman 均值为 0.9983，最小值为 0.9958；Kendall 均值为 0.9729。另逐一移除指标并重新计算，影响最大的指标为“年化利润”，移除后的 Spearman 相关系数为 0.9150。




图 9 100 次 TOPSIS 权重扰动的真实排名相关系数

直觉理解：相关系数接近 1 表示什么

Spearman 相关系数比较两次排名的先后顺序。接近 1 表示权重稍微变化时，大多数企业仍处于相近位置。它说明 TOPSIS 解释排名对小幅权重误差较稳定，但不代表 PD 模型、LGD 或资金成本也已经完成同样的敏感性检验。

12 模型评价、局限与扩展

12.1 模型优点

1. 风险主模型直接学习违约标签，且所有性能指标来自嵌套样本外预测；
2. 发票净额保留负数经济含义，连续月历显式记录经营断档；
3. 附件 2 不重复拟合缩放尺度，PD 和 TOPSIS 解释具有统一参照；
4. 流失率满足经济意义上的单调性，利率同时考虑收入和客户接受行为；
5. 额度优化严格执行预算、单户上下限和 D 级禁贷，并导出收益拆分；
6. 图表、Excel、网页和论文数字由同一次运行生成，降低手工抄录错误。

12.2 主要局限

第一，附件 1 只有 123 家企业，无法充分覆盖所有行业和经营状态。当前样本外验证比训练内评价可靠，但仍不能替代跨年份、跨地区的外部验证。

第二，LGD 为 60%、资金成本为 2.5%、问题 1 预算为 8000 万元，这些是显式情景假设，不是附件直接给出的事实。银行应按真实参数重跑，并比较参数变化对企业入选名单和收益的影响。

第三，模型假定 PD 在利率选择阶段不随利率变化。现实中高利率可能增加企业偿债

压力，使 PD 进一步上升。若有历史定价和贷后表现数据，可建立利率、PD 和流失率的联合模型。

第四，疫情行业识别依赖脱敏名称，信息不足的企业只能标记为未知。冲击结果适合用于压力测试，不适合作为真实行业风险的精确估计。

第五，当前线性目标会把入选企业推向单户上限，尚未包含企业真实资金需求、行业集中度、资本占用和组合尾部风险。

12.3 扩展方向

获得新增样本后，可按时间滚动进行外部验证和概率再校准；获得回收数据后，可把 LGD 从常数扩展为企业层面模型；获得申请额度后，可把单户上限改为 100 万元与实际需求的较小值；需要控制组合风险时，可增加行业额度上限、期望损失上限或 CVaR 约束。上述扩展均不改变“PD 估计、定价、组合优化”的主体结构。

13 结论

本文从发票净额和经营连续性出发，建立带正则、类别平衡和先验校正的监督 PD 模型，并用重复嵌套交叉验证获得严格样本外结果。模型 ROC-AUC 达到 0.856，A 至 D 档实际违约率依次上升，能够集中识别高风险企业。TOPSIS 被限定为经营质量辅助解释工具，从而避免综合评分与违约概率的概念混淆。

进一步地，本文用保序回归建立利率与客户流失率的单调关系，把留存后利息、违约损失和资金成本合并为单位额度期望收益，再通过混合整数规划满足预算、准入和单户额度约束。三问预算均被精确满足，原始 D 级获贷企业数为 0。疫情情景通过赔率调整后触发完整的重新评级、定价和额度优化。

模型的核心不是给企业生成一个孤立分数，而是建立从数据口径、风险概率、客户行为到银行资源配置的一致链条。每一步都能解释、复算和替换参数，这使模型既适合数学建模竞赛展示，也为后续接入真实银行数据保留了扩展空间。

参考文献

- [1] Hosmer D W, Lemeshow S, Sturdivant R X. Applied Logistic Regression. Wiley, 2013.
- [2] Hastie T, Tibshirani R, Friedman J. The Elements of Statistical Learning. Springer, 2009.
- [3] Hwang C L, Yoon K. Multiple Attribute Decision Making: Methods and Applications. Springer, 1981.
- [4] Barlow R E, Bartholomew D J, Bremner J M, Brunk H D. Statistical Inference under Order Restrictions. Wiley, 1972.